Laboratorijski delovni list 7

Grafi I: podatkovna struktura in osnovne metrike

Univerza v Mariboru · Fakulteta za naravoslovje in matematiko · Oddelek za fiziko

Programsko okolje: Python

Vse naloge rešujete **izključno v Pythonu** (virtualno okolje iz vaje 00).

- standardna knjižnica: `dict`, `set`, `collections.deque`
- `numpy`: `np.random.default_rng`, `np.unique`, `np.mean`
- `scipy.stats`: `poisson.pmf`; `matplotlib.pyplot`: `bar`, `plot`
- `networkx`: le za preverjanje rezultatov (`nx.average_clustering`, `nx.average_shortest_path_length`)

Rešitev oddate kot Jupyter zvezek `.ipynb` z izvedenimi celicami.

1 Teoretične osnove in motivacija

Realni sistemi so pogosto sestavljeni iz velikega števila povezanih komponent: proteini v celici, nevroni v možganih, ljudje v družbenih omrežjih, elektrarne v elektroenergetskem omrežju. Ne glede na področje jih lahko opišemo z **grafom**: množico **vozlišč** (komponent) in množico **povezav** (interakcij). Struktura grafa pogosto odločilno vpliva na dinamiko procesov na njem, na primer na širjenje bolezni ali sinhronizacijo. Na tej vaji napišemo lastno podatkovno strukturo za graf in izračunamo njegove osnovne metrike. Na naslednji vaji bomo generirali grafe različnih topologij.

Opis modela

Obravnavamo neusmerjene grafe brez zank in večkratnih povezav. Graf $G = (V, E)$ ima $n = |V|$ vozlišč in $m = |E|$ povezav. Shranimo ga kot **seznam sosednosti**: slovar, ki vsakemu vozlišču priredi množico njegovih sosedov.

Globalne metrike

Povprečna stopnja in **gostota** grafa sta

$$\langle k \rangle = \frac{2m}{n}, \qquad D = \frac{2m}{n(n-1)}. \tag{1}$$

Razdalja $d(u, v)$ je število povezav na najkrajši poti med vozliščema. Na povezanem grafu definiramo **povprečno najkrajšo pot** in **premer**:

$$L = \frac{1}{n(n-1)} \sum_{u \neq v} d(u, v), \qquad d_{\max} = \max_{u,v} d(u, v). \tag{2}$$

Razdalje od izbranega vozlišča do vseh ostalih izračunamo z **iskanjem v širino** (BFS): vozlišča obiskujemo po vrsti (FIFO), vsak nov sosed dobi razdaljo za 1 večjo od trenutnega vozlišča. Z BFS poiščemo tudi **povezane komponente** grafa.

Lokalne metrike

Stopnja vozlišča k_i je število njegovih sosedov. **Lokalna gručavost** pove, kolikšen delež parov sosedov je med seboj povezan:

$$c_i = \frac{2e_i}{k_i(k_i-1)}, \qquad C = \frac{1}{n}\sum_i c_i, \tag{3}$$

kjer je e_i število povezav med sosedi vozlišča i (za $k_i < 2$ vzamemo $c_i = 0$). C je **povprečna gručavost** grafa.

Dva referenčna modela

V **naključnem grafu** Erdős-Rényi $G(n,p)$ je vsak par vozlišč povezan z verjetnostjo p. Stopnje so porazdeljene binomsko, za velike n pa približno Poissonovo:

$$P(k) = \frac{\langle k\rangle^k e^{-\langle k\rangle}}{k!}, \qquad \langle k\rangle = p(n-1), \qquad C \approx p, \qquad L \approx \frac{\ln n}{\ln\langle k\rangle}. \tag{4}$$

V **pravilni obročasti mreži** je vsako od n vozlišč povezano s $k/2$ najbližjimi sosedi na vsaki strani. Zanjo velja

$$C = \frac{3(k-2)}{4(k-1)}, \qquad L \approx \frac{n}{2k}. \tag{5}$$

Naključni graf ima majhno gručavost in kratke poti, obroč pa veliko gručavost in dolge poti.

2 Pripravljalna naloga (analitični del)

P1. Majhen graf. Graf ima 6 vozlišč in povezave $(0,1)$, $(0,2)$, $(1,2)$, $(2,3)$, $(3,4)$, $(3,5)$, $(4,5)$. Narišite ga in izračunajte n, m, $\langle k\rangle$, D ter stopnje vseh vozlišč.

$n =$ _____ $m =$ _____ $\langle k\rangle =$ _____ $D =$ _____

P2. Gručavost. Za graf iz P1 izračunajte lokalne gručavosti vseh vozlišč in povprečno gručavost C.

vozlišče	0	1	2	3	4	5
k_i						
c_i						

Preglednica P2: Stopnje in lokalne gručavosti grafa iz P1.

$C =$ _____

P3. Razdalje. Za graf iz P1 zapišite razdalje od vozlišča 0 do vseh ostalih. Kolikšen je premer? Izračunajte L (vseh urejenih parov je 30). Kaj se zgodi, če odstranimo povezavo $(2,3)$?

$L =$ _____ $d_{\max} =$ _____

P4. Referenčna modela. Za $n = 200$ izračunajte $\langle k\rangle$, C in L za $G(n,p)$ s $p = 0{,}05$ ter C in L za obroč s $k = 4$ in $k = 10$.

$G(n,p)$: _____ obroč $k=4$: _____ obroč $k=10$: _____

3 Laboratorijske naloge na računalniku (Python)

Repozitorij

Začetna predloga je v repozitoriju predmeta: `07_vaje/vaje_07.ipynb`. V razdelku *Funkcije* dopolnite metode razreda `Graf` in funkcije z oznako `TODO`, v razdelku *Testno območje* pa sestavite graf iz P1.

Naloga 1: Podatkovna struktura grafa (20 min)

1. Dopolnite metode razreda `Graf`: `dodaj_vozlisce`, `dodaj_povezavo` (zank ne dodajamo, manjkajoča vozlišča dodamo samodejno), `odstrani_povezavo`, `odstrani_vozlisce` in `m`.
2. Dopolnite funkciji `povprecna_stopnja` in `gostota`.
3. Preverite, da podvojena povezava in zanka ne spremenita grafa iz P1. Na kopiji grafa odstranite povezavo $(2, 3)$ in vozlišče 5 ter izpišite seznam sosednosti.

```
class Graf:
    def __init__(self):
        self.sosedje = {} # vozlišče -> množica sosedov
    def dodaj_povezavo(self, u, v):
        ... # TODO
```

Količina	P1 (ročno)	Numerično
n, m	_____	_____
$\langle k \rangle$	_____	_____
D	_____	_____
n, m po odstranitvi	_____	_____

Preglednica 1: Osnovne lastnosti grafa iz P1.

Naloga 2: Gručavost (15 min)

Dopolnite funkciji `lokalna_grucavost(G, v)` in `povprecna_grucavost(G)`. Rezultate za graf iz P1 primerjajte s P2 in s funkcijo `nx.average_clustering`.

Količina	P2 (ročno)	Numerično	`networkx`
c_2	_____	_____	_____
c_3	_____	_____	_____
C	_____	_____	_____

Preglednica 2: Gručavost grafa iz P1.

Naloga 3: Najkrajše poti in komponente (25 min)

1. Dopolnite funkcijo `bfs(G, izvor)`, ki vrne slovar razdalj od izvora, z vrsto `collections.deque`.
2. Funkcija `komponente(G)` z BFS poišče povezane komponente. Dopolnite funkcijo `razdalje(G)`, ki na največji komponenti izračuna L in premer.
3. Rezultate primerjajte s P3 in z `nx.average_shortest_path_length`. Preverite, koliko komponent ima graf brez povezave $(2, 3)$.

Količina	P3 (ročno)	Numerično	`networkx`
razdalje od vozlišča 0	_____	_____	–
L	_____	_____	_____
premer	_____	_____	–
komponente brez $(2, 3)$	_____	_____	–

Preglednica 3: Razdalje v grafu iz P1.

Naloga 4: Naključni graf in obroč (30 min)

1. Dopolnite generatorja `nakljucni_graf(n, p)` in `obroc(n, k)`.
2. Za $n = 200$ izračunajte metrike za $G(n, p)$ s $p \in \{0{,}01;\ 0{,}02;\ 0{,}05;\ 0{,}1\}$ in za obroča s $k = 4$ in $k = 10$. Primerjajte jih s teoretičnimi napovedmi.
3. **Slika 1**: porazdelitev stopenj $P(k)$ za $G(1000;\ 0{,}01)$ in Poissonova porazdelitev z enakim $\langle k \rangle$.

Graf	$\langle k \rangle$ (teor.)	$\langle k \rangle$	C (teor.)	C	L (teor.)	L	največja komp.
$G(n;\ 0{,}01)$	_____	_____	_____	_____	_____	_____	_____
$G(n;\ 0{,}02)$	_____	_____	_____	_____	_____	_____	_____
$G(n;\ 0{,}05)$	_____	_____	_____	_____	_____	_____	_____
$G(n;\ 0{,}1)$	_____	_____	_____	_____	_____	_____	_____
obroč $k = 4$	4	_____	_____	_____	_____	_____	_____
obroč $k = 10$	10	_____	_____	_____	_____	_____	_____

Preglednica 4: Metrike naključnih grafov in obročev ($n = 200$).

4 Vprašanja za razpravo in zaključni zagovor

Razmislek 1: Izbira podatkovne strukture

Zakaj smo sosede shranili v množice in ne v sezname? Koliko pomnilnika potrebuje seznam sosednosti in koliko matrika sosednosti za graf z $n = 10^6$ vozlišči in $\langle k \rangle = 10$? Kdaj je matrika sosednosti vseeno ugodnejša?

Razmislek 2: Zahtevnost algoritmov

Kakšna je časovna zahtevnost BFS iz enega vozlišča in kakšna izračuna L za cel graf? Kako se z $\langle k \rangle$ spreminja čas izračuna lokalne gručavosti? Kako bi L ocenili za zelo velik graf?

Razmislek 3: Povezanost naključnega grafa

Pri $p = 0{,}01$ graf ni povezan. Pri kateri vrednosti $\langle k \rangle$ se v $G(n, p)$ pojavi velika (»orjaška«) komponenta? Zakaj se pri $p = 0{,}1$ izmerjeni L precej razlikuje od ocene $\ln n / \ln\langle k \rangle$?

Razmislek 4: Realna omrežja (domača naloga)

Realna omrežja imajo pogosto veliko gručavost kot obroč in kratke poti kot naključni graf. Poiščite podatke o enem realnem omrežju (npr. omrežje sodelovanja ali prijateljstev) in ocenite, ali ima to lastnost. Kako bi tak graf generirali? (Odgovor bomo iskali na vaji 8.)