Laboratorijski delovni list 8

Grafi II: generatorji topologij, izris in izvoz

Univerza v Mariboru · Fakulteta za naravoslovje in matematiko · Oddelek za fiziko

Programsko okolje: Python

Vse naloge rešujete **izključno v Pythonu** (virtualno okolje iz vaje 00).

- `numpy`: `np.random.default_rng`, `np.logspace`, `np.histogram`, `np.polyfit`, `np.add.at`
- `json`: `json.dump`, `json.load`; `pathlib`: `Path`
- `matplotlib.pyplot`: `semilogx`, `loglog`, `scatter`
- `networkx`: `nx.gnm_random_graph`, `nx.write_graphml`, `nx.read_graphml` (primerjava in izvoz)

Rešitev oddate kot Jupyter zvezek `.ipynb` z izvedenimi celicami.

1 Teoretične osnove in motivacija

Na vaji 7 smo videli, da ima naključni graf kratke poti in majhno gručavost, pravilni obroč pa veliko gručavost in dolge poti. Realna omrežja pogosto združujejo obe lastnosti (**mali svet**), poleg tega pa imajo nekaj vozlišč z zelo veliko povezavami (**zvezdišča**, angl. *hubs*). Danes napišemo generatorja, ki ti lastnosti pojasnita, grafe narišemo in jih izvozimo v standardne zapise.

Opis modela

Uporabimo razred `Graf` z vaje 7. Generiramo grafe Watts-Strogatz (prevezan obroč) in Barabási-Albert (rast s preferenčnim pripenjanjem), izmerimo njihove metrike, jih narišemo s krožno in silno usmerjeno razporeditvijo ter izvozimo v zapise CSV, JSON in GraphML.

Model Watts-Strogatz (mali svet)

Začnemo s pravilnim obročem z n vozlišči in stopnjo k. Vsako povezavo $(i, i+j)$ z verjetnostjo p **prevežemo**: krajišče $i+j$ zamenjamo z naključnim vozliščem w, pri čemer se izognemo zankam in podvojenim povezavam. Število povezav se ne spremeni, pričakovano število prevezanih povezav je $p\,nk/2$. Pri $p = 0$ imamo obroč, pri $p = 1$ približno naključni graf. Že nekaj prevezanih povezav ustvari »bližnjice«, ki močno skrajšajo $L(p)$, gručavost $C(p)$ pa ostane skoraj nespremenjena. Za obroč velja

$$C(0) = \frac{3(k-2)}{4(k-1)}, \qquad L(0) \approx \frac{n}{2k}. \tag{1}$$

Model Barabási-Albert (brezlestvična omrežja)

Začnemo s polnim grafom z $m+1$ vozlišči. V vsakem koraku dodamo novo vozlišče in ga povežemo z m različnimi obstoječimi vozlišči. Verjetnost, da izberemo vozlišče i, je sorazmerna z njegovo stopnjo (**preferenčno pripenjanje**):

$$\Pi(k_i) = \frac{k_i}{\sum_j k_j}. \tag{2}$$

Izbiro izvedemo preprosto: hranimo seznam krajišč vseh povezav, v katerem se vozlišče i pojavi k_i-krat, in iz njega enakomerno žrebamo. V zveznem približku stopnja vozlišča, dodanega v času

t_i, raste kot $k_i(t) = m\sqrt{t/t_i}$, od koder sledi potenčna porazdelitev stopenj

$$P(k) \approx 2m^2 k^{-3}, \qquad P(K \geq k) = \left(\frac{m}{k}\right)^2, \qquad k_{\max} \approx m\sqrt{n}. \tag{3}$$

Ker je $P(k)$ pri velikih k zelo majhen, ga ocenimo s histogramom z **logaritemskimi razredi** in vsako frekvenco delimo s širino razreda.

Izris grafa

Pri **krožni razporeditvi** vozlišča enakomerno razporedimo po krožnici. Pri **Fruchterman-Reingoldovi** (silno usmerjeni) razporeditvi se vsi pari vozlišč odbijajo s silo k_{opt}^2/d, povezana vozlišča pa se privlačijo s silo d^2/k_{opt}, kjer je k_{opt} želena razdalja med vozlišči. Vozlišča premikamo v smeri rezultante, največji premik pa omejimo s »temperaturo«, ki jo postopoma zmanjšujemo.

Zapisi grafov

- **seznam povezav (CSV)**: vrstica `vir,cilj` za vsako povezavo, preprost in kompakten zapis,
- **JSON**: slovar s seznamom vozlišč in seznamom povezav, preprost za branje v različnih jezikih,
- **GraphML**: zapis XML, ki ga berejo programi za analizo omrežij (npr. Gephi, Cytoscape) in lahko hrani tudi atribute vozlišč in povezav.

2 Pripravljalna naloga (analitični del)

P1. Obroč in prevezovanje. Za obroč z $n = 500$ in $k = 10$ izračunajte $C(0)$, $L(0)$ in število povezav. Koliko povezav v povprečju prevežemo pri $p = 0{,}01$?

$C(0) =$ _____ $L(0) =$ _____ $m =$ _____ prevezanih: _____

P2. Barabási-Albert. Za $n = 2000$ in $m = 2$ ocenite število povezav, $\langle k \rangle$, $k_{\max}$ in pričakovano število vozlišč s stopnjo $k \geq 20$. Koliko takih vozlišč bi pričakovali v naključnem grafu z enakim $\langle k \rangle$?

$\langle k \rangle =$ _____ $k_{\max} \approx$ _____ $N(k \geq 20) \approx$ _____

P3. Potenčni zakon. Iz $k_i(t) = m\sqrt{t/t_i}$ pokažite, da je delež vozlišč s stopnjo večjo od k enak $(m/k)^2$, in od tod izpeljite $P(k) \propto k^{-3}$. Kateri naklon pričakujete na grafu $P(k)$ v log–log merilu?

naklon: _____

P4. Razporeditev in pomnilnik. Pri kateri razdalji sta sili med dvema povezanima vozliščema v Fruchterman-Reingoldovi razporeditvi v ravnovesju? Koliko elementov ima matrika sosednosti za graf iz P2 in koliko vrstic seznam povezav?

$d_{\text{ravn}} =$ _____ matrika: _____ seznam: _____

3 Laboratorijske naloge na računalniku (Python)

Repozitorij

Začetna predloga je v repozitoriju predmeta: `08_vaje/vaje_08.ipynb`. Razred `Graf` in metrike z vaje 7 so že vneseni. V razdelku *Funkcije* dopolnite telesa funkcij z oznako `TODO`, v razdelku *Testno območje* pa preverite rezultata nalog P1 in P2.

Naloga 1: Mali svet (25 min)

1. Dopolnite funkcijo `watts_strogatz(n, k, p)`. V *Testnem območju* preverite število prevezanih povezav pri $p = 0{,}01$.
2. Za $n = 500$, $k = 10$ in 13 vrednosti p med 10^{-4} in 1 (`np.logspace`) izračunajte $C(p)/C(0)$ in $L(p)/L(0)$, povprečeni po dveh ponovitvah.
3. **Slika 1**: obe razmerji v odvisnosti od p (logaritemska os x). V katerem območju p je graf »mali svet«?

p	10^{-3}	10^{-2}	10^{-1}	1
$C(p)/C(0)$	_____	_____	_____	_____
$L(p)/L(0)$	_____	_____	_____	_____

Preglednica 1: Gručavost in povprečna pot v modelu Watts-Strogatz ($n = 500$, $k = 10$).

Naloga 2: Preferenčno pripenjanje (25 min)

1. Dopolnite funkcijo `barabasi_albert(n, m)` s seznamom krajišč.
2. Generirajte graf z $n = 2000$ in $m = 2$ ter naključni graf z enakim številom vozlišč in povezav (`nx.gnm_random_graph`).
3. **Slika 2**: porazdelitev stopenj obeh grafov v log–log merilu. Za BA uporabite logaritemske razrede in prilagodite premico. Primerjajte naklon s P3.

```
robovi = np.unique(np.logspace(np.log10(2), np.log10(k_max + 1), 15).astype(int))
h, _ = np.histogram(stopnje, bins=robovi)
P = h / np.diff(robovi) / len(stopnje)
```

Količina	BA (P2)	BA	naključni graf
$\langle k \rangle$	_____	_____	_____
$k_{\max}$	_____	_____	_____
delež vozlišč s $k \geq 20$	_____	_____	_____
C	–	_____	_____
naklon $P(k)$	_____	_____	–

Preglednica 2: Primerjava grafa Barabási-Albert in naključnega grafa ($n = 2000$, $m = 2$).

Naloga 3: Izris grafov (20 min)

1. Dopolnite izračun sil v funkciji `fr_razporeditev(G)`: odbojne sile med vsemi pari (z `numpy` brez zank) in privlačne sile po povezavah (`np.add.at`).
2. **Slika 3** (dve vrsti po štiri panele): obroč ($n = 60$, $k = 4$), WS s $p = 0{,}1$, BA z $m = 1$ in BA z $m = 2$, zgoraj v krožni, spodaj v Fruchterman-Reingoldovi razporeditvi. Velikost in barva vozlišča naj ustrezata stopnji.
3. Katera razporeditev bolje pokaže strukturo posameznega grafa? Kje opazite zvezdišča?

Graf	najvišja stopnja	opis strukture (FR)
obroč	_____	_____
WS $p = 0{,}1$	_____	_____
BA $m = 1$	_____	_____
BA $m = 2$	_____	_____

Preglednica 3: Izris grafov z 60 vozlišči.

Naloga 4: Izvoz in uvoz (20 min)

1. Dopolnite funkcije `izvozi_csv`, `uvozi_csv`, `izvozi_json` in `uvozi_json`.
2. Graf BA iz naloge 2 izvozite v mapo `izvoz/` v zapisih CSV, JSON in GraphML (`nx.write_graphml`), ga ponovno uvozite in preverite, da je enak izvirniku.
3. Primerjajte velikosti datotek z velikostjo matrike sosednosti (1 bajt na element). Datoteko GraphML lahko odprete v programu Gephi.

Zapis	velikost [kB]	uvoženi n, m	enak izvirniku
CSV	_____	_____	_____
JSON	_____	_____	_____
GraphML	_____	_____	_____
matrika sosednosti	_____	–	–

Preglednica 4: Zapisi grafa BA ($n = 2000$, $m = 2$).

4 Vprašanja za razpravo in zaključni zagovor

Razmislek 1: Zakaj mali svet?

Zakaj nekaj prevezanih povezav močno skrajša povprečno pot, gručavosti pa skoraj ne spremeni? Navedite primer realnega omrežja z lastnostmi malega sveta in pojasnite, kaj to pomeni za širjenje informacij ali bolezni po njem.

Razmislek 2: Zvezdišča

Zakaj preferenčno pripenjanje ustvari zvezdišča? Kaj se zgodi z grafom BA, če odstranimo 5 % naključno izbranih vozlišč, in kaj, če odstranimo 5 % vozlišč z največjo stopnjo? Zakaj je izmerjeni naklon $P(k)$ nekoliko drugačen od -3?

Razmislek 3: Razporeditev in zahtevnost

Kakšna je časovna zahtevnost enega koraka Fruchterman-Reingoldove razporeditve? Zakaj je za grafe z več tisoč vozlišči neuporabna brez izboljšav? Zakaj krožna razporeditev pri grafu BA ne pokaže njegove strukture?

Razmislek 4: Prostorski graf (domača naloga)

V mapi `GraphAL/graph_generators.py` je osnutek funkcije `Morita`: vozlišča imajo naključne lege in »uspešnost« f_i, povezavo (i, j) pa ustvarimo, če je $f_i f_j / d_{ij}^{\delta} > \Theta$, prag Θ pa nastavimo tako, da je $\langle k \rangle = 5$. Popravite funkcijo (npr. `np.random(0, 1, [N, 2])` ni veljaven klic) in raziščite, kako je porazdelitev stopenj odvisna od δ.