Laboratorijski delovni list 13

Nevronske mreže: propagacija naprej in vzvratno razširjanje napake

Univerza v Mariboru · Fakulteta za naravoslovje in matematiko · Oddelek za fiziko

Programsko okolje: Python

Vse naloge rešujete **izključno v Pythonu** (virtualno okolje iz vaje 00).

- `numpy`: matrično množenje `@`, `np.tanh`, `np.exp`, `np.random.default_rng`, `np.ndindex`, `np.meshgrid`
- `matplotlib.pyplot`: `plot`, `loglog`, `contourf`, `scatter`

Knjižnic za strojno učenje (`scikit-learn`, `pytorch`) ne uporabljamo: mrežo napišemo sami. Rešitev oddate kot Jupyter zvezek `.ipynb` z izvedenimi celicami.

1 Teoretične osnove in motivacija

Umetne nevronske mreže so prilagodljivi modeli, ki se iz podatkov naučijo zveze med vhodom in izhodom. V fiziki jih uporabljamo za aproksimacijo funkcij, razvrščanje signalov (npr. v fiziki delcev), pospeševanje simulacij in reševanje inverznih problemov. Na tej vaji napišemo večplastni perceptron od začetka: propagacijo naprej, izračun gradienta z vzvratnim razširjanjem napake in učenje z gradientnim spustom, ki ga poznamo z vaje 6.

Opis modela

Mreža z arhitekturo $[n_0, n_1, \ldots, n_L]$ ima n_0 vhodov, $L-1$ skritih plasti in n_L izhodov. Vsaka plast je polno povezana z naslednjo. Uteži poiščemo tako, da je izguba na učnih podatkih čim manjša.

Propagacija naprej

Paket N vhodnih vektorjev zložimo v matriko $\mathbf{A}_0 = X$ velikosti $N \times n_0$. Plast l ima matriko uteži W_l $(n_{l-1} \times n_l)$, vektor pragov $\mathbf{b}_l$ in aktivacijsko funkcijo f_l:

$$Z_l = A_{l-1} W_l + \mathbf{b}_l, \qquad A_l = f_l(Z_l), \qquad l = 1, \ldots, L. \tag{1}$$

Izhod mreže je $\hat{Y} = A_L$. Pogoste aktivacijske funkcije so

$$\tanh z, \quad \sigma(z) = \frac{1}{1+e^{-z}}, \quad \mathrm{ReLU}(z) = \max(0, z), \qquad \sigma' = \sigma(1-\sigma), \quad \tanh' = 1 - \tanh^2. \tag{2}$$

Brez nelinearnih aktivacij bi bila mreža le linearna preslikava, ne glede na število plasti.

Izguba

Za regresijo uporabimo povprečno kvadratno napako, za razvrščanje v dva razreda (izhod s sigmoido) pa binarno navzkrižno entropijo:

$$\mathcal{L}_{\mathrm{MSE}} = \frac{1}{N} \sum_i (\hat{y}_i - y_i)^2, \qquad \mathcal{L}_{\mathrm{BCE}} = -\frac{1}{N} \sum_i \left[y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i) \right]. \tag{3}$$

Vzvratno razširjanje napake

Gradient izgube po vseh utežeh izračunamo z verižnim pravilom od izhoda proti vhodu. Naj bo $\Delta_l = \partial\mathcal{L}/\partial Z_l$ (matrika $N \times n_l$). Potem je

$$\Delta_L = \frac{\partial \mathcal{L}}{\partial A_L} \odot f_L'(Z_L), \qquad \Delta_{l-1} = \left(\Delta_l W_l^\top\right) \odot f_{l-1}'(Z_{l-1}), \tag{4}$$

$$\frac{\partial \mathcal{L}}{\partial W_l} = A_{l-1}^\top \Delta_l, \qquad \frac{\partial \mathcal{L}}{\partial \mathbf{b}_l} = \sum_{i=1}^{N} (\Delta_l)_{i,:}, \tag{5}$$

kjer je $\odot$ množenje po elementih. Uteži nato posodobimo z gradientnim spustom $W_l \leftarrow W_l - \eta\, \partial\mathcal{L}/\partial W_l$. Pravilnost implementacije preverimo z **numeričnim gradientom** (centralne diference, vaja 6).

Inicializacija, posplošitev in prekomerno prilagajanje

Uteži začetno izberemo naključno, sicer bi vsi nevroni v plasti ostali enaki. Pri Xavierjevi inicializaciji je $W_{ij} \sim \mathcal{N}(0, 1/n_{l-1})$, pragovi so nič. Uspešnost mreže merimo na **testnih podatkih**, ki jih pri učenju nismo uporabili. Mreža z (pre)velikim številom parametrov se lahko nauči šuma v učnih podatkih (prekomerno prilagajanje), zato je testna napaka večja od učne.

2 Pripravljalna naloga (analitični del)

P1. Aktivacijske funkcije. Izračunajte vrednosti in odvode funkcij tanh, σ in ReLU pri $z = 0$. Pokažite, da je $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$. Kje je odvod ReLU nedefiniran?

	tanh	σ	ReLU
$f(0)$	_____	_____	_____
$f'(0)$	_____	_____	_____

Preglednica P1: Aktivacijske funkcije pri $z = 0$.

P2. Število parametrov. Koliko uteži in pragov imajo mreže z arhitekturo $[1, 10, 1]$, $[2, 8, 1]$ in $[2, 2, 1]$? Zapišite splošno formulo.

$[1, 10, 1]$: _____ $[2, 8, 1]$: _____ $[2, 2, 1]$: _____

P3. En nevron na roke. Nevron s sigmoido ima uteži $\mathbf{w} = (0{,}5;\ -1)$ in prag $b = 0{,}2$. Za vhod $\mathbf{x} = (1;\ 2)$ in želeni izhod $y = 1$ izračunajte z, $\hat{y}$, $\mathcal{L}_{\text{MSE}}$ ter gradienta $\partial\mathcal{L}/\partial\mathbf{w}$ in $\partial\mathcal{L}/\partial b$.

z = _____ $\hat{y}$ = _____ $\mathcal{L}$ = _____ $\partial\mathcal{L}/\partial\mathbf{w}$ = _____ $\partial\mathcal{L}/\partial b$ = _____

P4. Linearna ločljivost. Pokažite, da en nevron (brez skrite plasti) ne more pravilno razvrstiti točk dveh koncentričnih obročev. Najmanj koliko skritih nevronov s funkcijo tanh bi po vašem mnenju potrebovali, da bi odločitvena meja obdala notranji obroč?

odgovor: _____

3 Laboratorijske naloge na računalniku (Python)

Repozitorij

Začetna predloga je v repozitoriju predmeta: `13_vaje/vaje_13.ipynb`. V razdelku *Funkcije* dopolnite telesa funkcij z oznako `TODO`, v razdelku *Testno območje* pa preverite rezultate nalog P1–P3.

Naloga 1: Aktivacijske funkcije (15 min)

Dopolnite funkcijo `aktivacija(z, ime, odvod)` za funkcije `tanh`, `sigmoid`, `relu` in `linear`. **Slika 1** (dva panela): funkcije in njihovi odvodi na intervalu $[-4, 4]$. Analitične odvode primerjajte z numeričnimi (`np.gradient`).

Funkcija	tanh	σ	ReLU	linearna
mediana napake odvoda	_____	_____	_____	_____
največja napaka odvoda	_____	_____	_____	_____

Preglednica 1: Primerjava analitičnih in numeričnih odvodov.

Naloga 2: Propagacija naprej in nazaj (25 min)

1. Dopolnite funkcije `ustvari_mrezo` (Xavierjeva inicializacija), `naprej`, `izguba` (MSE) in `nazaj`.
2. Na mreži $[2, 3, 1]$ (skrita plast tanh, izhod linearen) s petimi naključnimi vzorci primerjajte gradient, izračunan z vzvratnim razširjanjem, z numeričnim gradientom (funkcija `numericni_gradient`). Izračunajte relativno napako $\|g_{\text{bp}} - g_{\text{num}}\| / \|g_{\text{bp}} + g_{\text{num}}\|$.

```
for l in reversed(range(len(mreza))):
    grad[l] = (As[l].T @ delta, delta.sum(axis=0))
    if l > 0:
        delta = ... # TODO: (delta W_l^T) * f'(Z_{l-1})
```

Plast	$\|\partial\mathcal{L}/\partial W\|$	rel. napaka $\partial\mathcal{L}/\partial W$	rel. napaka $\partial\mathcal{L}/\partial \mathbf{b}$
1 (skrita)	_____	_____	_____
2 (izhodna)	_____	_____	_____

Preglednica 2: Preverjanje gradienta.

Naloga 3: Regresija (25 min)

1. Dopolnite funkcijo `uci` (gradientni spust na celotnem paketu).
2. Mrežo $[1, 10, 1]$ (skrita plast tanh, izhod linearen) naučite funkcije $y = \sin 2\pi x$ iz 40 šumnih točk ($\sigma_{\text{šum}} = 0{,}1$) s 5000 epohami pri $\eta \in \{0{,}01;\ 0{,}05;\ 0{,}2\}$. Testno napako izračunajte na 200 točkah brez šuma.
3. **Slika 2** (dva panela): (A) učna izguba v odvisnosti od epohe (log–log), (B) napovedi mrež in učni podatki.
4. Pri $\eta = 0{,}05$ ponovite učenje za 1, 3, 10 in 30 skritih nevronov.

Mreža	η	MSE učna	MSE testna
$[1, 10, 1]$	0,01	_____	_____
$[1, 10, 1]$	0,05	_____	_____
$[1, 10, 1]$	0,2	_____	_____
$[1, 1, 1]$	0,05	_____	_____
$[1, 3, 1]$	0,05	_____	_____
$[1, 30, 1]$	0,05	_____	_____

Preglednica 3: Regresija funkcije $\sin 2\pi x$.

Naloga 4: Razvrščanje (25 min)

Generirajte dva koncentrična obroča (polmera 1 in 2, šum 0,15, 200 točk vsak). Mreže $[2, n, 1]$ s skrito plastjo tanh in izhodom s sigmoido naučite z izgubo BCE ($\eta = 1$, 3000 epoh) za $n = 1, 2, 4, 8$. **Slika 3**: odločitvene meje ($\hat{y} = 0{,}5$) in podatki za vse štiri mreže.

Skritih nevronov n	1	2	4	8
število parametrov	_____	_____	_____	_____
$\mathcal{L}_{\text{BCE}}$	_____	_____	_____	_____
točnost	_____	_____	_____	_____

Preglednica 4: Razvrščanje dveh koncentričnih obročev.

4 Vprašanja za razpravo in zaključni zagovor

Razmislek 1: Zakaj vzvratno razširjanje?

Koliko izračunov izgube bi potrebovali za numerični gradient mreže z 10^6 utežmi in koliko za gradient z vzvratnim razširjanjem? Zakaj je preverjanje z numeričnim gradientom kljub temu pomembno?

Razmislek 2: Učni korak

Zakaj se mreža pri $\eta = 0{,}01$ v 5000 epohah ne nauči funkcije, pri $\eta = 0{,}2$ pa je rezultat slabši kot pri $\eta = 0{,}05$? Primerjajte z ugotovitvami o stabilnosti gradientnega spusta z vaje 6.

Razmislek 3: Kapaciteta mreže

Kako se z naraščanjem števila skritih nevronov spreminjata učna in testna napaka? Kdaj pride do prekomernega prilagajanja? Zakaj ena skrita plast z dovolj nevroni v principu lahko aproksimira poljubno zvezno funkcijo, v praksi pa uporabljamo globlje mreže?

Razmislek 4: Fizikalna uporaba (domača naloga)

Z mrežo $[1, n, 1]$ aproksimirajte Lennard-Jonesov potencial z vaje 4 na intervalu $r \in [0{,}95;\ 2{,}5]$. Kako bi zagotovili, da je sila, izračunana kot odvod naučene mreže, dovolj natančna za simulacijo molekularne dinamike?