Laboratorijski delovni list 14

Grupiranje podatkov: mere podobnosti časovnih vrst (dodatna vaja)

Univerza v Mariboru · Fakulteta za naravoslovje in matematiko · Oddelek za fiziko

Programsko okolje: Python

Vse naloge rešujete **izključno v Pythonu** (virtualno okolje iz vaje 00).

- `numpy`: `np.fft.rfft`, `np.linalg.norm`, `np.bincount`, `np.argsort`
- `scipy.cluster.hierarchy`: `linkage`, `fcluster`, `dendrogram`; `scipy.spatial.distance`: `squareform`
- `matplotlib.pyplot`: `plot`, `imshow`

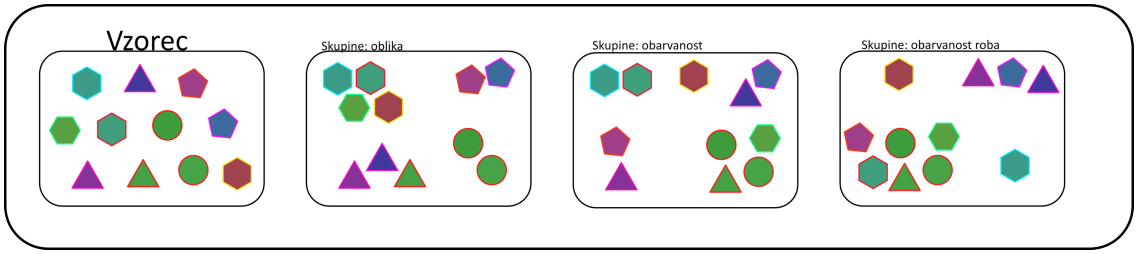
Rešitev oddate kot Jupyter zvezek `.ipynb` z izvedenimi celicami.

1 Teoretične osnove in motivacija

Pri analizi meritev pogosto želimo podatke razdeliti v bolj homogene skupine, ne da bi vnaprej poznali njihove oznake: signale senzorjev glede na vrsto dogodka, zvezde glede na spremenljivost sija, celice glede na dinamiko kalcijevih nihanj. Ključna odločitev pri takem **grupiranju** (angl. *clustering*) je izbira **mere podobnosti**: kdaj sta si dve časovni vrsti »podobni«? Na tej vaji primerjamo štiri mere na umetnih časovnih vrstah, katerih pravo pripadnost skupinam poznamo.

Opis modela

Generiramo $N = 24$ sinusnih časovnih vrst dolžine $T = 100$ v $K = 4$ skupinah. Vrste v isti skupini imajo podobno frekvenco, a različno amplitudo in (po želji) naključno fazo ter šum. Za vsak par vrst izračunamo razdaljo, vrste hierarhično grupiramo in rezultat primerjamo s pravimi skupinami.



Slika 1: Grupiranje časovnih vrst: iz množice signalov želimo ugotoviti, katere vrste imajo podobno dinamiko.

Mere razdalje

Naj bosta $X = (x_1, \ldots, x_T)$ in $Y = (y_1, \ldots, y_T)$ časovni vrsti.

Razdalja Minkowskega (za $p = 2$ evklidska) primerja vrednosti ob istih časih:

$$D_p(X, Y) = \left(\sum_{i=1}^{T} |x_i - y_i|^p \right)^{1/p}. \tag{1}$$

Korelacijska razdalja je $d_r = 1 - r$, kjer je r Pearsonov korelacijski koeficient

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}. \tag{2}$$

Ni občutljiva na premik in raztezek vrednosti, je pa občutljiva na časovni zamik.

Dinamično časovno ukrivljanje (DTW, angl. *dynamic time warping*) dovoli, da se časovni osi lokalno raztegneta. Iščemo pot od $(1,1)$ do (n,m) z najmanjšo skupno ceno, ki se lahko premika le desno, navzgor ali diagonalno. Z dinamičnim programiranjem izračunamo kumulativno matriko

$$D_{i,j} = |x_i - y_j| + \min\left(D_{i-1,j},\ D_{i,j-1},\ D_{i-1,j-1}\right), \qquad D_{0,0} = 0, \tag{3}$$

razdalja DTW pa je $D_{n,m}$. Zahtevnost je $\mathcal{O}(nm)$; z oknom Sakoe-Chiba ($|i-j| \le w$) jo zmanjšamo na $\mathcal{O}(nw)$.

Spektralna razdalja primerja normirana amplitudna spektra $S_X = |\mathcal{F}(X - \bar{X})|/\|\cdot\|$, ki nista odvisna od faze in amplitude signala:

$$d_S(X,Y) = \|S_X - S_Y\|. \tag{4}$$

Hierarhično grupiranje in čistost

Pri **aglomerativnem grupiranju** začnemo z vsako vrsto v svoji gruči in zaporedoma združujemo najbližji gruči. Pri **povprečni povezavi** je razdalja med gručama povprečje razdalj med vsemi pari njunih članov. Zaporedje združevanj prikažemo z **dendrogramom**, ki ga »prerežemo« na višini, kjer dobimo K gruč. Ujemanje s pravimi skupinami merimo s **čistostjo**:

$$\text{čistost} = \frac{1}{N}\sum_{c} \max_{k} |c \cap k|, \tag{5}$$

kjer vsota teče po gručah c, k pa so prave skupine. Popolno grupiranje ima čistost 1.

2 Pripravljalna naloga (analitični del)

P1. Evklidska razdalja in faza. Pokažite, da za dolgi vrsti $x_i = \sin(\omega i)$ in $y_i = \sin(\omega i + \varphi)$ velja $D_2^2/T \approx 1 - \cos\varphi$. Kolikšna je D_2^2/T za $\varphi = 0$, $\pi/2$ in π? Kaj to pomeni za grupiranje signalov z enako frekvenco in različno fazo?

$\varphi = 0$: _____ $\pi/2$: _____ π: _____

P2. Korelacija. Kolikšen je korelacijski koeficient istih vrst kot v P1? Kolikšen je (približno) za $\sin(\omega i)$ in $\sin(2\omega i)$ na celem številu period?

$r(\varphi) =$ _____ $r(\omega, 2\omega) \approx$ _____

P3. DTW na roke. Za $X = (0,1,2,3)$ in $Y = (0,0,1,2)$ izpolnite kumulativno matriko $D_{i,j}$ s ceno $|x_i - y_j|$ in določite razdaljo DTW. Primerjajte jo z razdaljo $L_1 = \sum_i |x_i - y_i|$.

$D_{i,j}$	$y_1 = 0$	$y_2 = 0$	$y_3 = 1$	$y_4 = 2$
$x_1 = 0$				
$x_2 = 1$				
$x_3 = 2$				
$x_4 = 3$				

Preglednica P3: Kumulativna matrika DTW.

DTW = _____ L_1 = _____

P4. Čistost. Šest vrst s pravimi skupinami $(0,0,0,1,1,2)$ smo razvrstili v gruče $(1,1,2,2,2,3)$. Kolikšna je čistost? Kolikšna je čistost, če vse vrste damo v eno gručo, in kolikšna, če vsaka vrsta tvori svojo gručo? Zakaj čistost sama ni dobra mera, če število gruč ni določeno vnaprej?

čistost: _____ ena gruča: _____ vsaka svoja: _____

3 Laboratorijske naloge na računalniku (Python)

Repozitorij

Začetna predloga je v repozitoriju predmeta: `14_vaje/vaje_14.ipynb`. V razdelku *Funkcije* dopolnite telesa funkcij z oznako `TODO`, v razdelku *Testno območje* pa preverite rezultate nalog P1–P4.

Naloga 1: Generiranje časovnih vrst (15 min)

Dopolnite funkcijo `generiraj(N, K, T, faza)`. Vrsta v skupini k ima frekvenco $f_k(1 \pm 0{,}05)$, kjer je $f_k \in \{0{,}02;\ 0{,}035;\ 0{,}05;\ 0{,}08\}$ ciklov na vzorec, amplitudo $A \in [0{,}5;\ 1]$, fazo 0 ali naključno na $[0, 2\pi)$ in Gaussov šum s standardnim odklonom $0{,}1\,A$. **Slika 2** (dva panela): vrste brez zamika faze in z naključno fazo, obarvane po skupinah.

Skupina	0	1	2	3
perioda [vzorcev]	_____	_____	_____	_____
število period v vrsti	_____	_____	_____	_____

Preglednica 1: Lastnosti skupin.

Naloga 2: Matrike razdalj (25 min)

1. Dopolnite funkcije `razdalja_evklid`, `razdalja_korelacija`, `razdalja_dtw` (z oknom w) in `razdalja_spekter`.
2. Za vrste z naključno fazo izračunajte matrike razdalj za vse štiri mere (DTW z $w = 10$) in izmerite čas izračuna.
3. **Slika 3**: štiri matrike razdalj z vrstami, urejenimi po pravih skupinah. Pri kateri meri so jasno vidni diagonalni bloki?

```
for i in range(1, n + 1):
    for j in range(max(1, i - w), min(m, i + w) + 1):
        D[i, j] = abs(x[i - 1] - y[j - 1]) + min(D[i - 1, j], D[i, j - 1], D[i - 1, j -
            1])
```

Mera	evklidska	korelacijska	DTW ($w = 10$)	spekter
čas izračuna [s]	_____	_____	_____	_____
vidni bloki (da/ne)	_____	_____	_____	_____

Preglednica 2: Matrike razdalj za vrste z naključno fazo.

Naloga 3: Hierarhično grupiranje (25 min)

1. Dopolnite funkcijo `cistost(oznake, resnica)`. Funkcija `grupiraj(D, K)` z `scipy.cluster.hierarchy` izvede grupiranje s povprečno povezavo in vrne K gruč.
2. Grupirajte vrste z naključno fazo z vsemi štirimi merami. **Slika 4**: dendrogrami (oznake listov so prave skupine).

Mera	evklidska	korelacijska	DTW	spekter
čistost	_____	_____	_____	_____

Preglednica 3: Čistost grupiranja vrst z naključno fazo.

Naloga 4: Vpliv faze (25 min)

Za podatke brez zamika faze in z naključno fazo izračunajte povprečno čistost petih neodvisnih ponovitev (različna semena generatorja) za vse štiri mere.

Podatki	evklidska	korelacijska	DTW	spekter
brez faze	_____	_____	_____	_____
naključna faza	_____	_____	_____	_____

Preglednica 4: Povprečna čistost petih ponovitev.

4 Vprašanja za razpravo in zaključni zagovor

Razmislek 1: Izbira mere

Zakaj evklidska in korelacijska razdalja pri naključni fazi odpovesta, spektralna pa ne? V katerih primerih bi bila evklidska razdalja vseeno prava izbira (npr. ko je čas dogodka pomemben)?

Razmislek 2: DTW

Zakaj DTW le delno odpravi vpliv faze? Kako na rezultat vplivata širina okna w in različna frekvenca vrst? Kakšna je časovna zahtevnost izračuna matrike razdalj DTW za N vrst dolžine T?

Razmislek 3: Število gruč

Pri vaji smo pravo število skupin K poznali. Kako bi ga določili iz dendrograma ali s kriterijem, kot je silhuetni koeficient? Kako bi se rezultat spremenil z drugo vrsto povezave (najbližji sosed, najbolj oddaljen sosed)?

Razmislek 4: Realni podatki (domača naloga)

Uporabite izmerjene urne temperature iz `11_vaje/navodila/Vreme_urni.csv`: vsak dan je časovna vrsta s 24 točkami. Dneve grupirajte s korelacijsko razdaljo v 4 gruče in preverite, ali gruče ustrezajo letnim časom ali vremenskim tipom (jasno, oblačno).